

# WhatsApp Chatanalyse

Skydive Hilversum Community

*Oktober 2024 – Februari 2026*

**Lucas Joshua**

Studentnummer: 1905781

Vak: Data Analysis & Visualisation

Datum: April 2026



## 1 Inleiding

Ik spring zelf bij Skydive Hilversum, en de groepschat is voor mij dagelijkse kost, niet alleen sociaal, maar ook operationeel: is de DZ open, wat is het weer, wat is er gebeurd? Dat maakte deze dataset persoonlijk interessant: ik wist dat er veel in de chat gebeurt op heel verschillende vlakken, maar had geen idee hoe dat er kwantitatief uitzag.

De dataset omvat 4.143 berichten van 122 unieke afzenders over oktober 2024 tot en met maart 2026: een periode van 17 maanden met twee volledige vliegseizoenen. Het berichtenaantal ligt onder de bovenste richtlijn van 10.000, maar de dataset is rijk door de combinatie van een lange tijdsperiode, 122 actieve deelnemers en verkeer dat drie functies tegelijk dekt: sociaal, operationeel en veiligheidsgerelateerd. Die gelaagdheid maakt het ook met 4.143 berichten mogelijk om patronen te vinden die in een homogenere of kortere chat verborgen zouden blijven.


Dit verslag volgt vijf invalshoeken: welke emoji's er worden gebruikt (Les 2), wanneer de chat het drukst is (Les 3), hoe de berichtendrukke is verdeeld over de dag (Les 4), of er een verband is tussen drukke dagen en incidenten (Les 5), en of incidentberichten er inhoudelijk anders uitzien dan gewone berichten (Les 6). Incidenten detecteer ik automatisch op basis van woorden als 'noodlanding', 'gesloten' en 'Airmet': termen die in gewone gesprekken nauwelijks voorkomen.

Voor de analyse zijn aanvullende features geconstrueerd: incident-labels op basis van domeinspecifieke sleutelwoorden en karakter-trigram representaties van berichten, zodat schrijfpatronen los van woordkeuze vergeleken kunnen worden. Alle stappen van preprocessing tot visualisatie zijn geautomatiseerd in een pipeline (zie GitHub), zodat de analyse reproduceerbaar is met één commando.

## 2 Categorische visualisatie

### 2.1 Emoji-gebruik per categorie

De groep telt 154 leden, waarvan 122 daadwerkelijk berichten stuurden in de meetperiode: verschillende generaties, van circa 20 tot 70 jaar, van instructeur tot beginner. Je zou verwachten dat zo'n diverse groep een brede spreiding aan emoji-gebruik laat zien. Dat is niet wat de data laat zien. Bijna driekwart van alle emoji's valt in exact twee categorieën: Positief (41,1%) en Humor (31,0%). De overige categorieën zijn statistisch verwaarloosbaar. 122 actieve afzenders, maar één gedeeld emotioneel register. Die concentratie is alleen zichtbaar als je de verdeling meet; als je door de chat scrolt, zie je variatie. De data zegt iets anders: de community heeft ondanks haar diversiteit een opvallend homogeen emoji-vocabulaire, een teken van gedeelde cultuur.



**Figuur 1** Genormaliseerde emoji-verdeling per categorie. Positief en Humor domineren met samen >72% (Skydive Hilversum okt 2024–mrt 2026).

### 2.2 Reflectie


Ik heb bewust gekozen voor een gesorteerde staafgrafiek in plaats van een taartdiagram. Staaflengtes vergelijken is makkelijker dan de hoeken van taartpunten schatten: je ziet meteen wat groter is, zonder te hoeven gissen. Ik heb ook bewust gekozen om op frequentie te sorteren in plaats van alfabetisch, omdat ik het verhaal wil vertellen: dat verhaal begint bij de grootste categorie. Een alfabetische volgorde zou de lezer zelf laten zoeken naar het patroon, terwijl ik het direct zichtbaar wil maken.

Het Gestalt-principe Gelijkenis (Similarity) zorgt ervoor dat vergelijkbare aandelen direct opvallen door vergelijkbare staaflengtes. Figuur/Achtergrond maakt de gekleurde balken zichtbaar op de witte achtergrond. Een beperking: de categorie-indeling is subjectief; een gestandaardiseerde emoji-ontologie zou de classificatie robuuster maken. Verder is dit een beschrijvende verdeling: dat Positief en Humor domineren, kan ook komen doordat een klein aantal actieve gebruikers verhoudingsgewijs veel emoji sturen. De grafiek toont het patroon, niet de oorzaak ervan.

### 3 Tijdreeksanalyse

#### 3.1 Chatactiviteit per uur van de dag

Het patroon dat ik verwachtte te zien: een avondpiek, omdat mensen dan tijd hebben om te appen. Dat is inderdaad zichtbaar, maar de interessantere bevinding zit in de uren daarvoor. Tussen 12:00 en 16:00 is de chat vrijwel stil: gemiddeld minder dan 5 berichten per uur. Dat zijn exact de uren waarop een springdag op zijn hoogtepunt is. De community is buiten, in de lucht, en de chat zwijgt. Zodra de vluchten stoppen, om 17:00-18:00, explodeert de activiteit: de 18:00-piek haalt 433 berichten, zo'n 10% van alle berichten op één uur. De chat is geen achtergrondkanaal dat de hele dag door gebruikt wordt, maar een instrument dat opstaat als de springdag stopt. Dat patroon is alleen zichtbaar als je de uurverdeling meet.



**Figuur 2** Chatactiviteit per uur van de dag. Piek om 18:00 met 433 berichten (ca. 10% van totaal). Rood = piekuur; grijs = overige uren.

#### 3.2 Reflectie

Ik heb gekozen voor een staafgrafiek in plaats van een lijndiagram, omdat de uren van de dag losse categorieën zijn. Een lijndiagram suggereert dat er een vloeiende overgang is van uur naar uur, maar dat klopt niet: 17:00 en 18:00 zijn aparte momenten, geen continuüm. De rode kleur voor het piekuur is een bewuste keuze: de boodschap moet opvallen nog voordat de lezer de assen leest. Dit is het Figuur/Achtergrond-principe: het oog gaat automatisch naar het afwijkende element. De annotatie bij de piek voegt de exacte waarde toe zonder de grafiek druk te maken.

Een beperking: aggregatie over de volledige periode verbergt seizoenspatronen. In de zomer, met langere vliegdagen, zou de piek mogelijk later uitvallen. Een uitsplitsing naar zomer- vs. wintermaanden is een logische vervolgstap. Daarnaast is de koppeling tussen de 18:00-piek en het einde van de springdag een plausibele interpretatie, maar geen bewezen oorzaak. Een alternatieve verklaring is dat 18:00 simpelweg het moment is waarop mensen überhaupt meer vrije tijd hebben, los van springen. Deze data alleen is niet voldoende om die verklaringen van elkaar te onderscheiden.


## 4 Distributievevisualisatie

### 4.1 Poisson-model: globaal versus tijdsafhankelijk

Hoeveel berichten vallen er gemiddeld per uur? En wat als je dat vergelijkt met wat je statistisch zou verwachten? Dat is de kern van dit onderdeel. Een simpel model gaat ervan uit dat elk uur van de dag even druk is, gemiddeld zo'n 8 berichten. Maar dat klopt niet met wat de data laat zien: dit model verwacht dat slechts 1% van de uren écht druk wordt (meer dan 15 berichten), terwijl dat in de praktijk 15,7% is, vijftien keer zo vaak. Een model dat rekening houdt met het dagritme past de data veel beter. De avondpiek is geen toeval, maar een structureel patroon.

#### Uurafhankelijke Poisson past beter

Oct 2024 – Mar 2026 · per uur-interval · globale  $\lambda$  vlakkt dagritme te veel uit · uitschieters ( $>P99=2$ )  $\approx 4.0\%$



**Figuur 3** Waargenomen uurverdeling (grijs) vs. globale Poisson-fit (blauw gestippeld) en tijdsafhankelijke Poisson-fit (rood). Het tijdsafhankelijke model sluit beter aan op de data. 15,7% van de uren overschrijdt de drempel van 15 berichten/uur, vijftien keer vaker dan het globale model voorspelt.

### 4.2 Reflectie

De y-as toont relatieve frequentie (benadering van kans), zodat de waargenomen verdeling direct te vergelijken is met de theoretische Poisson-kansen. Ik heb gekozen voor een overlay van histogram en modelcurven, omdat ik de twee modellen direct naast de werkelijkheid wil laten zien. Twee losse grafieken hadden dezelfde informatie gebracht, maar dan moet de lezer zelf het verschil reconstrueren. Door alles in één plot te zetten, wordt de vergelijking onmiddellijk zichtbaar. Gestalt Gemeenschappelijk lot (Common Fate) speelt hier een rol: de grijze staven en de rode lijn stijgen allebei naar rechts naarmate het uurvolume toeneemt, en dat maakt de relatie instinctief leesbaar.


Wat ik prettig vond aan deze aanpak: het model is ook visueel intuïtief. De verwachte verdeling heeft een duidelijke vorm, en het verschil met de werkelijkheid is meteen zichtbaar. Een beperking is dat het model ervan uitgaat dat berichten onafhankelijk van elkaar zijn, maar mensen reageren op elkaar, dus er zit ritme in de chat dat het model niet volledig vangt. Bovendien toont een betere modelfit alleen dat het tijdsafhankelijke model de data beter

beschrijft; het verklaart niet waarom het dagritme bestaat. Andere factoren, zoals werk- of schooltijden die niets met springen te maken hebben, kunnen hetzelfde patroon produceren.

## 5 Relatievisualisatie

### 5.1 Correlatie dagelijks volume en incidentactiviteit

De vraag die ik hier stel is niet of incidenten meer berichten opleveren, dat is te verwachten. De vraag is: in welke mate?  $r = 0.38$  klinkt als een redelijk verband, maar het verklaart slechts 14% van de variantie in dagelijkse activiteit. Ruim 85% van de drukte in de chat heeft dus niets met incidenten te maken. Er zijn dagen met meerdere incidentberichten en weinig totale activiteit, en drukke dagen zonder ook maar één incidentbericht. De community is levendig ongeacht of er iets misgaat. Dat maakt incidentactiviteit een zichtbare piek, maar geen verklaring voor het basisniveau van de chat. Wat dat basisniveau bepaalt, vliegweer, aankondigingen, sociale dynamiek, is iets wat de correlatie niet beantwoordt maar wel opwerpt.



**Figuur 4** Scatterplot dagelijks berichtenvolume vs. aantal incidentberichten per dag.  $r = 0.38$ ,  $p < 0.001$ ; regressielijn met 95% betrouwbaarheidsband. Rood = incidentdagen, grijs = normale dagen.



## 5.2 Reflectie

Ik heb bewust gekozen voor een scatterplot omdat ik een verband tussen twee variabelen wil laten zien: dagvolume en incidentactiviteit. Een lijngrafiek over tijd zou dat verband verstoppen. De regressielijn met 95% betrouwbaarheidsband heb ik toegevoegd omdat een losse trendlijn te stellig is: de band laat zien hoe zeker je kunt zijn over de richting van het verband. Zonder die band zou de lezer niet kunnen inschatten of de relatie stevig is of door een paar uitschieters wordt gedreven. Het kleurgebruik volgt Gestalt Gelijkenis: rood = incidentdagen, grijs = normaal, consistent door het hele rapport.

Een beperking: een scatterplot toont een verband, maar vertelt niet wat wat veroorzaakt. Gaat de drukte vooraf aan het incident, of volgt hij erop? Dat is een vraag voor vervolgonderzoek. De voetnoot 'observationeel · geen causaliteit' stuurt de interpretatie alvast de goede kant op. Een derde factor, zoals vliegweer, kan tegelijk de chatactiviteit verhogen én het incidentrisico vergroten, zonder dat drukte en incidenten elkaar direct veroorzaken. Dat soort confounding is niet uit te sluiten op basis van correlatie alleen.

## 6 Dimensiereductie

### 6.1 t-SNE en UMAP vergeleken


Voor dit onderdeel heb ik elk bericht omgezet naar een karakter-trigram profiel, een vectorrepresentatie op basis van drielettercombinaties, en die profielen teruggebracht naar twee dimensies zodat je ze kunt plotten. Elk punt is één bericht: rood voor incidentgerelateerd, grijs voor de rest. Ik heb twee methoden op exact dezelfde data uitgevoerd om te zien of de bevinding standhoudt.

De vergelijking laat een interessant verschil zien. t-SNE, dat lokale structuur maximaliseert, toont de incidentberichten geconcentreerd in de linkerbovenhoek. UMAP, dat ook de globale structuur bewaart, spreidt ze over de hele boog. Welk beeld klopt dan? Belangrijk om te beseffen is dat de assen zelf geen directe semantische betekenis hebben: zowel bij t-SNE als bij UMAP zijn de coördinaten wiskundige abstracties zonder interpreteerbare eenheid. Wat telt, is de positie van punten ten opzichte van elkaar. In deze configuratie wekt UMAP minder sterk de indruk van een hard cluster dan t-SNE, omdat t-SNE vergelijkbare punten actief naar elkaar toe duwt en daarmee de indruk van clustering kan versterken. Of dat een artefact is of een echte structuur, is niet met zekerheid te zeggen op basis van deze data alleen. Wat wel consistent is: in beide projecties zitten incidentberichten niet duidelijk afgezonderd van de rest.

Het antwoord op mijn vraag is dan ook: de community communiceert sneller bij een incident, maar niet in een duidelijk andere stijl. Ze zijn herkenbaar aan specifieke woorden, niet aan hun algemene schrijfpatroon.

Wat ik eigenlijk het meest had willen zien, is of je de leeftijdsverschillen in de groep kunt terugzien in hoe mensen schrijven. De groep loopt van 20 tot 70 jaar: jonge springer naast ervaren instructeur. Als je de chat leest, heb je het gevoel dat er een verschil zit in toon en woordkeuze, maar de projectie laat dat niet zien. Alles zit door elkaar. Dat vind ik eerlijk gezegd jammer, want dit had het meest persoonlijke inzicht van het verslag kunnen zijn. De meest waarschijnlijke verklaring is dat het vakjargon van het springen zo dominant is dat subtielere stijlverschillen erin verdwijnen. Iedereen schrijft 'DZ', 'gesloten', 'Airmet', ongeacht leeftijd.

Een andere mogelijkheid is dat de representatie tekortschiet. Karakter-trigrammen vangen schrijfstijl op een vrij grof niveau. Fijnere kenmerken zoals zinslengte, gebruik van aanhalingstekens, leestekens of afkortingen zouden wellicht wél een leeftijdssignaal laten zien. Dat zou een volgende stap zijn: niet minder data, maar rijkere features.



**Figuur 5** t-SNE (links) vs UMAP (rechts) op dezelfde karakter-trigrammen. t-SNE toont incidentberichten geconcentreerd linksboven; UMAP spreidt ze over de boog. Rood = incidentgerelateerd, grijs = regulier.

## 6.2 Reflectie

Ik heb bewust gekozen om beide methoden naast elkaar te tonen in plaats van er één uit te pikken, omdat het verschil tussen t-SNE en UMAP zelf de belangrijkste les is. Als je alleen t-SNE had gezien, had je kunnen denken dat incidentberichten een eigen stijlgroep vormen. UMAP corrigeert dat beeld. Die methodologische vergelijking voegt meer toe dan een mooiere versie van hetzelfde plaatje.

De keuze voor karakter-trigrammen in plaats van woorden was bewust: trigrammen vangen schrijfstijl beter dan woordkeuze, omdat ze ook spellingspatronen, afkortingen en tikfouten meenemen. Voor een WhatsApp-chat is dat relevanter dan voor formele tekst. Ik heb gekozen voor kleur als enige onderscheid tussen de twee groepen zodat de lezer zelf kan beoordelen of er structuur zichtbaar is, zonder dat de visualisatie de conclusie al oplegt.

Gestalt Nabijheid (Proximity) is hier de kern: punten dicht bij elkaar hebben een vergelijkbaar schrijfprofiel. Figuur/Achtergrond werkt via kleur: rood steekt af tegen grijs. Dat de incidentberichten in UMAP geen eigen cluster vormen, suggereert dat de herkenning via specifieke woorden gaat, niet via een andere algemene schrijfstijl. Tegelijk is dit een negatief resultaat: afwezigheid van zichtbaar cluster is geen bewijs van afwezigheid van structuur. De karakter-trigrammen zijn mogelijk te grof om fijnere stijlverschillen te detecteren, en een schijnbaar gemengde projectie kan ook het gevolg zijn van de feature-keuze in plaats van de werkelijkheid.

## 7 Conclusie

De vijf visualisaties samen geven een completer beeld van de chat dan ik van tevoren had verwacht. Het gaat niet alleen over incidenten: de chat heeft een eigen ritme, een herkenbare sfeer en een gedeelde taal die veel meer zegt dan je op het eerste gezicht zou denken. Elke analyse onthulde een ander aspect van dezelfde community.

[Hoofdstuk 2 \(Figuur 1\)](#) laat zien dat de community structureel een luchtige toon heeft: Positief en Humor domineren met meer dan 72% van het emoji-gebruik. [Hoofdstuk 3 \(Figuur 2\)](#) koppelt dit aan de timing: de 18:00-piek is de digitale nabespreking van de springdag, herkenbaar als springer, maar de scherpte ervan verraste me. [Hoofdstuk 4 \(Figuur 3\)](#) toont dat een simpel model tekortschiet: drukke uren komen vijftien keer vaker voor dan verwacht. Het dagritme is structureel, niet toevallig.

[Hoofdstuk 5 \(Figuur 4\)](#) legt de verbinding met incidenten: er is een duidelijk positief verband tussen drukke dagen en incidentactiviteit, maar incidenten zijn niet de enige verklaring voor drukte. [Hoofdstuk 6 \(Figuur 5\)](#) levert het meest verrassende en tegelijk moeilijkst te duiden inzicht: de community communiceert sneller bij een incident, maar niet in andere woorden. Wat ik eigenlijk had gehoopt te ontdekken, was of je de verschillende leeftijdsgroepen in de chat kon herkennen aan hun schrijfstijl. Van 20 tot 70 jaar zitten er in de groep heel verschillende mensen. Maar de UMAP laat zien dat er nauwelijks verschil is. De gedeelde taal van de springwereld lijkt sterker dan de leeftijdsverschillen.

Als ik verder zou kijken, wil ik graag weten of het uurpatroon verandert tussen zomer en winter, want langere vliegdagen betekenen waarschijnlijk een latere avondpiek. En of er op rustige dagen subtiel andere gespreksthema's zijn dan op drukke dagen. Dat soort vragen kun je met tekst-analyse verder verkennen, maar dat valt buiten de scope van dit verslag.

Code: [github.com/Lucas-Joshua/dav-chat-analysis](https://github.com/Lucas-Joshua/dav-chat-analysis)

Lucas Joshua · Studentnummer 1905781 · Data Analysis & Visualisation · April 2026